

國立清華大學通訊工程研究所

碩士論文

Institute of Communications Engineering

National Tsing Hua University

Master Thesis

基於 YOLO 之雷達目標偵測演算法

YOLO-CFAR: a Novel CFAR Target Detection

Method Based on YOLO

系別：通訊工程研究所

學號：108064545

研 究 生：林郁庭 (Yu-Ting Lin)

指導教授：鍾偉和 教授 (Prof. Wei-Ho Chung)

中 華 民 國 一 一 〇 年 七 月

July 2021

摘要

恆虛警率(Constant False Alarm Rate, 簡稱 CFAR)檢測是雷達系統中常見的目標偵測算法。然而,傳統的 CFAR 檢測器在非均質環境(Nonhomogeneous scenario)中,例如:多目標環境(Multiple target scenario)及雜波環境(Clutter scenario),其檢測能力會明顯下降。雖然基於深度學習(Deep Learning, 簡稱 DL)之 CFAR 檢測器(簡稱 DL-CFAR)改善了多目標環境中的檢測效能,但其依舊無法解決雜波環境中檢測效能低下的問題。造成傳統 CFAR 及 DL-CFAR 效能低下的原因通常是其對雜訊電平(Noise level)的估計不夠準確,為了提高 CFAR 檢測效能,本研究提出了一種新的想法,即是將距離都卜勒圖(Range Doppler map, 簡稱 RD map)視為一張圖片,使用深度學習中物件偵測之模型來偵測目標,少了估計雜訊的步驟,可以減少造成錯誤延遲(Error propagation)的可能性,並且提升 CFAR 檢測器效能。因本研究所應用之物件偵測模型為 YOLO(You Only Look Once),因此將此算法命名為:YOLO-CFAR。

在本研究中,提出了一種基於深度學習之物件偵測模型的目標偵測算法,我們除了引入 YOLO 模型外,也使用動態範圍壓縮(Dynamic Range Compression, 簡稱 DRC)對資料作前處理,除此之外,我們還加入深度神經網路(Deep Neural Network, 簡稱 DNN),進一步提升 YOLO-CFAR 在多目標環境中的檢測效能。最後,經由模擬結果顯示,本研究提出的方法除了在均質環境(Homogeneous scenario)中有良好的效能外,在非均質環境中的效能更明顯優於其他現有 DL 算法及傳統算法,並且其檢測速度可達即時(Real time)檢測。

關鍵字: 恆虛警率、目標偵測、深度學習、物件偵測、YOLO、動態範圍壓縮

Abstract

Constant False Alarm Rate (CFAR) detection is a common target detection algorithm in radar systems. However, nonhomogeneous scenarios, such as multi-target scenarios and clutter scenarios, can dramatically affect the CFAR target detection performance because of the erroneous noise level estimation. In order to improve the CFAR target detection performance in nonhomogeneous scenarios, we propose a novel CFAR target detection method, based on a deep learning model: you only look once (YOLO), called YOLO-CFAR. The proposed CFAR scheme does not require to estimate the noise level and use deep learning model for object detection to detect targets in an RD map. The possibility of error propagation caused by inaccurate noise level estimation decreased, thus getting better CFAR target detection performance.

In this paper, we not only introduce YOLO in CFAR target detection, but also use dynamic range compression (DRC) to pre-process the input data and add deep neural network (DNN) to further improve the performance of YOLO-CFAR. Simulation results demonstrate that YOLO-CFAR outperforms other CFAR schemes especially in nonhomogeneous scenarios, furthermore, YOLO-CFAR can achieve real-time detection.

Keywords: constant false alarm rate (CFAR), target detection, deep learning, object detection, YOLO, dynamic range compression (DRC)

誌謝

這本碩士論文能夠如期完成，需要感謝許多人，在此獻上最大敬意。

首先要感謝的是我的指導教授 鍾偉和教授的悉心指導，在研究所的兩年中，提供了學生良好的學習環境，感謝教授在學生報告時總是耐心的傾聽、包容學生的錯誤以及提供寶貴的建議，並且在研究方向上給予學生很大的發揮空間，教授在專業研究上嚴謹的態度，更深刻影響著我。在這研究所的兩年間，非常感謝教授的指導與照顧！

接下來要感謝的是實驗室的研究助理 林家宏學長，學長在研究方向的部份給了我很大的幫助，讓我能夠更快的步上軌道，並且在整個研究過程中也不厭其煩的給予指導以及協助，非常感謝學長即使忙碌也盡量抽出時間與我討論我的研究。

再來要特別感謝實驗室的博班學生 張馨元同學，感謝馨元在我的研究遇到困難時，總是會與我一起討論解決辦法，並且提供我非常有用的建議以及方向，謝謝馨元在研究所期間對我的幫助。另外還要感謝實驗室的所有夥伴們，謝謝大家這兩年間的照顧，大家在研究、課業和生活上的互相幫助，讓我覺得有夥伴真好，謝謝大家豐富了我的研究生涯。

最後要感謝的是我的家人，謝謝父母在我的求學過程中給予最大的支持與鼓勵，讓我能順利完成碩士學位。研究所畢業是我學生生涯的終點，卻也是人生另一個階段的起點，未來雖然存在著許多不確定性，但我還是會勇往直前！

目錄

摘要.....	i
Abstract.....	ii
致謝.....	iii
圖次.....	vii
第一章 緒論.....	1
1.1 研究背景與動機.....	1
1.2 論文章節內容安排.....	3
第二章 相關背景及系統模型.....	4
2.1 相關背景.....	4
2.1.1 調頻連續波雷達.....	4
2.1.2 距離都卜勒圖.....	5
2.2 系統模型.....	6
第三章 恆虛警率.....	8
3.1 恆虛警率概念.....	8
3.2 恆虛警率檢測器.....	9
3.2.1 單元平均恆虛警率檢測器.....	11

3.2.2	最大單元平均恆虛警率檢測器.....	12
3.2.3	最小單元平均恆虛警率檢測器.....	14
3.2.4	有序統計恆虛警率檢測器.....	15
3.2.5	深度學習恆虛警率檢測器.....	16
第四章	本論文所提出 YOLO-CFAR 演算法	17
4.1	總覽 YOLO-CFAR.....	17
4.2	動態範圍壓縮.....	19
4.3	YOLO 介紹	21
4.3.1	深度學習之物件偵測介紹.....	21
4.3.2	YOLO 技術介紹	22
4.3.3	簡化 YOLO 模型	26
4.4	深度神經網路.....	27
第五章	模擬結果與分析.....	28
5.1	模擬環境與比較對象.....	28
5.2	訓練資料產生與設定.....	28
5.3	模擬結果.....	28
5.3.1	單目標環境.....	29
5.3.2	多目標環境.....	31

5.3.3	雜波環境.....	33
5.3.4	加入深度神經網路與否之比較.....	36
5.3.5	使用動態範圍壓縮與使用截斷運算之比較.....	37
第六章	結論.....	38
	參考文獻.....	39



圖次

圖 一、線性調頻訊號之(a)時域圖(b)頻域圖	4
圖 二、雷達之參數估計原理示意圖	5
圖 三、雷達距離都卜勒圖	5
圖 四、產生 CCM 流程圖	7
圖 五、CFAR 檢測器之二維結構.....	9
圖 六、CFAR 檢測器之一維結構.....	10
圖 七、CA-CFAR 之一維結構.....	11
圖 八、GO-CFAR 之一維結構.....	12
圖 九、SO-CFAR 之一維結構.....	14
圖 十、OS-CFAR 之一維結構.....	15
圖 十一、DL-CFAR 之流程圖[7].....	16
圖 十二、YOLO-CFAR 示意圖.....	17
圖 十三、YOLO-CFAR 流程示意圖.....	18
圖 十四、動態範圍壓縮	20
圖 十五、一階段式與兩階段式模型之流程圖	21
圖 十六、YOLO 偵測示意圖[12].....	22
圖 十七、邊界框的預測值與實際值之示意圖[8].....	23

圖 十八、YOLOv3 之網路架構.....	25
圖 十九、簡化後之 YOLOv3 網路架構.....	26
圖 二十、密集神經網路之架構圖	27
圖 二十一、單目標環境且 $SNR = 20\text{ dB}$	30
圖 二十二、單目標環境且 $SNR = 25\text{ dB}$	30
圖 二十三、單目標環境且 $SNR = 30\text{ dB}$	30
圖 二十四、兩個目標且 $SNR = 20\text{ dB}$	32
圖 二十五、三個目標且 $SNR = 20\text{ dB}$	32
圖 二十六、四個目標且 $SNR = 20\text{ dB}$	32
圖 二十七、單目標且 $SNR = 20\text{ dB}$ 、 $CNR = 10\text{ dB}$	34
圖 二十八、單目標且 $SNR = 20\text{ dB}$ 、 $CNR = 15\text{ dB}$	34
圖 二十九、單目標且 $SNR = 20\text{ dB}$ 、 $CNR = 20\text{ dB}$	34
圖 三十、兩個目標且 $SNR = 20\text{ dB}$ 、 $CNR = 20\text{ dB}$	35
圖 三十一、三個目標且 $SNR = 20\text{ dB}$ 、 $CNR = 20\text{ dB}$	35
圖 三十二、四個目標且 $SNR = 20\text{ dB}$ 、 $CNR = 20\text{ dB}$	35
圖 三十三、兩個目標且 $SNR = 20\text{ dB}$	36
圖 三十四、三個目標且 $SNR = 20\text{ dB}$	36
圖 三十五、四個目標且 $SNR = 20\text{ dB}$	36
圖 三十六、動態範圍壓縮與截斷運算之比較	37

第一章 緒論

1.1 研究背景與動機

雷達系統中基本目標檢測算法是對接收到的訊號與固定閾值(Threshold)進行比較，若超過此閾值則判斷目標物存在。恆虛警率(Constant False Alarm Rate，簡稱 CFAR)可以在避免使用固定閾值時可能發生的錯誤檢測[1]、[2]，並且可透過調整閾值來保持恆定的虛警率，其核心概念是根據被測單元(Cell Under Test，簡稱 CUT)周圍的相鄰單元(Surrounding cell)來估計距離都卜勒圖(Range-Doppler map，簡稱 RD map)中的雜訊電平(Noise level)，並設定適當的閾值以檢測目標。單元平均恆虛警率(Cell Averaging Constant False Alarm Rate，簡稱 CA-CFAR)[1]利用參考單元(Reference cell)功率的算術平均值作為 Noise level 的估計。最大單元平均恆虛警率(Greatest Of Cell Averaging Constant False Alarm Rate，簡稱 GO-CFAR)[3]為 CA-CFAR 的一種變形，其可以降低虛警率(False Alarm Rate，簡稱 P_{fa})。儘管兩種檢測器在均質環境(Homogeneous scenario)中均有不錯的效能，但他們的效能在多目標環境(Multi-target scenario)中皆會因為對 Noise level 錯誤的估計而下降。因此，為了改善 CFAR 檢測器在多目標環境中的效能，最小單元平均恆虛警率(Smallest Of Cell Averaging Constant False Alarm Rate，簡稱 SO-CFAR)[4]被提出。但是在密集的多目標環境中，SO-CFAR 無法顯著的提升檢測效能，而有序統計量恆虛警率(Order Statistic Constant False Alarm Rate，簡稱 OS-CFAR)[5]、[6]可以解決此類問題。

因上述傳統 CFAR 檢測器易受目標旁瓣問題(Side-lobe issue)及多目標環境中之目標遮蔽效應(Masking effect)的影響造成效能下降，因此基於深度學習之恆虛警率(Deep Learning Constant False Alarm Rate，簡稱 DL-CFAR)[7]被提出來解

決上述的兩個問題，其模型學習了 RD map 中的目標結構，並消除了這些結構以獲得具有純雜訊的 RD map，該 RD map 可用於更準確地估計 Noise level，因此 DL-CFAR 之效能在單目標環境及多目標環境皆勝過上述所提到的傳統 CFAR 檢測器。

受到 DL-CFAR 之啟發，我們認為既然已經可以利用深度學習模型來學習目標的特徵並且移除之，也就是說，我們同樣可以利用深度學習模型來識別、偵測目標，如此一來，也可以避開因為 Noise level 估計不準確而造成效能下降的問題。因此本研究所提出基於 YOLO[8]之 CFAR 算法，命名為 YOLO-CFAR，其同樣是應用深度學習的技術，與 DL-CFAR 之差別為 YOLO-CFAR 是直接對 RD map 上的目標做偵測，而 DL-CFAR 則是移除 RD map 上的目標並且對該 RD map 做 Noise level 的估計。

在本論文中，我們歸納出三種會使得 Noise level 估計地不準確而造成 CFAR 檢測器效能下降之原因，分別是旁瓣問題、遮蔽效應及雜波邊緣(Clutter edge)。雖然 DL-CFAR 可解決前兩者，但在雜波環境中，其效能依然會嚴重的下降，而 YOLO-CFAR 在單目標和多目標環境中，不僅不會受到旁瓣問題及遮蔽效應之影響，即使在雜波環境中，只要目標特徵還存在，YOLO-CFAR 就可以偵測到目標。因此，YOLO-CFAR 不管是在均質環境或是非均質環境中都可以保持良好的效能。

1.2 論文章節內容安排

本論文總共分為六個章節，第一章說明 CFAR 傳統算法演進與本論文之研究動機，第二章介紹雷達相關背景及系統架構，第三章為 CFAR 的簡介及現有方法介紹，第四章則介紹所提出的基於 YOLO 所設計的 CFAR 算法流程，第五章針對本論文提出的 YOLO-CFAR 進行模擬與結果分析，第六章為本論文的結論。




第二章 相關背景及系統模型

2.1 相關背景

2.1.1 調頻連續波雷達

雷達的主要功能是用於檢測和定位反射物體，通過發射電磁訊號並且接收由目標反射的回波訊號來進行檢測，回波訊號不僅表示目標存在，且利用回波訊號與發射訊號的比較，可以確定目標位置和其他與目標有關的訊息，例如：相對速度。

調頻連續波雷達(Frequency Modulated Continuous Wave Radar，簡稱 FMCW Radar)[9]、[10]是一種通過對連續訊號進行頻率調變來獲取目標訊息的技術。FMCW Radar 之傳送天線發射線性調頻訊號(Chirp signal)，Chirp signal 是一個正弦曲線，其頻率隨時間線性增加，如圖一所示，發射訊號經目標物反射由接收天線接收，發射訊號與接收訊號之間所產生之時間延遲(Time delay)和都卜勒頻率偏移(Doppler frequency shift)可用來估計目標物相對於雷達的距離(Range)與速度(Velocity)[11]、[12]，如圖二所示。



圖一、線性調頻訊號之(a)時域圖(b)頻域圖

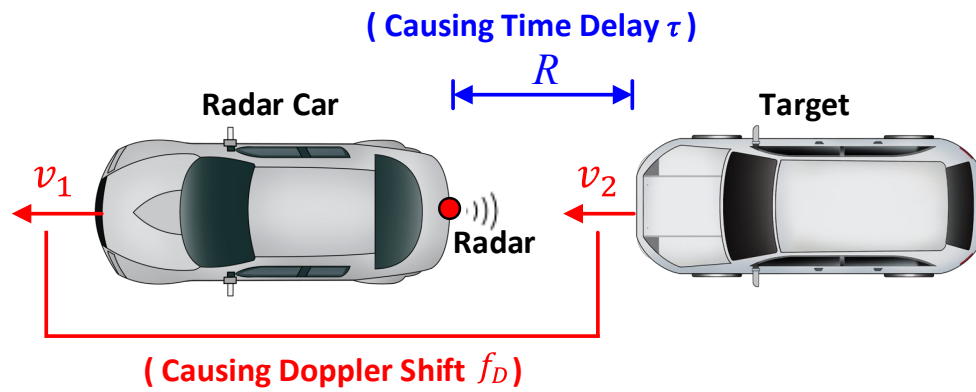


圖 二、雷達之參數估計原理示意圖

2.1.2 距離都卜勒圖

距離都普勒圖(Range Doppler map，簡稱 RD map)為 FMCW Radar 中之訊號經過二維快速傅立葉轉換(Two-dimensional Fourier Transform，簡稱 2D FFT)的結果，其橫軸與縱軸分別表示目標物與雷達之相對距離與相對速度，如圖三所示。

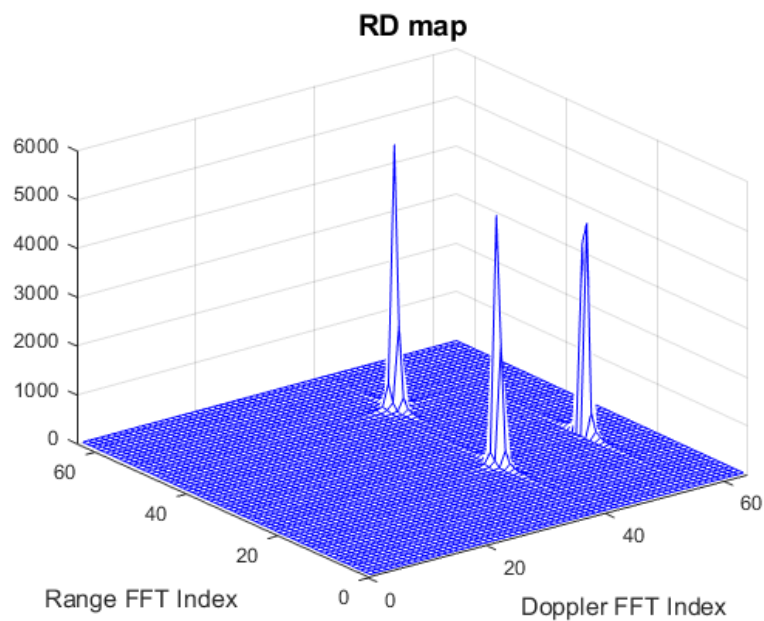


圖 三、雷達距離都卜勒圖

2.2 系統模型

此小節將介紹如何利用雷達之發射訊號與接收訊號來得到目標訊息(此處指目標相對雷達之距離與都卜勒速度)，並且產生 RD map[7]。在 FMCW Radar 中，利用通道係數來導出目標訊息，由目標返回的第 k 個樣本和第 l 個 Chirp 的通道係數可表示為[7]、[10]：

$$(\mathbf{H})_{k,l} = \sum_{h=0}^{H-1} b_h e^{j2\pi f_{D,h} l T_C} e^{-j2\pi f_{\text{beat},h} k T_S} e^{j\varphi_h}, \quad (1)$$

其中 \mathbf{H} 為由 H 個目標返回所組成的通道係數矩陣(Channel Coefficient Matrix，簡稱 CCM)， T_C 和 T_S 分別表示線性調頻長度(Chirp duration)與取樣週期(Sampling period)， b_h 、 $f_{D,h}$ 、 $f_{\text{beat},h}$ 和 φ_h 分別為與第 h 個目標返回相關之複數振幅(Complex amplitude)、都卜勒頻移(Doppler shift)、拍頻(Beat frequency)和隨機相位旋轉(Random phase rotation)，其中 $f_{D,h}$ 和 $f_{\text{beat},h}$ 兩個頻率分別包含相對速度和距離的資訊，經過 2D FFT 後即可估計出目標的相對速度及距離。

在 FMCW radar 中 CCM 的產生如圖四所示，我們發送一個由 M 個 Chirp signal 組成的幀(Frame)，然後將發送和接收到的 Chirp signal 混合成 M 個中頻(Intermediate Frequency，簡稱 IF)訊號。接下來，我們對每個 IF signal 提取 N 個樣本，如圖四中所看到的，CCM 是由這些樣本組成的行串聯而成的，通過對 CCM \mathbf{H} 執行 2D FFT 即可生成 RD map，可以表示為：

$$\begin{aligned} \text{RDM}(n, m) &= |\text{2D FFT}(\mathbf{H})(n, m)|^2 \\ &= \left| \sum_{k=0}^{N-1} \sum_{l=0}^{M-1} (\mathbf{H})_{k,l} e^{j2\pi l m / M} e^{j2\pi k n / N} \right|^2, \end{aligned} \quad (2)$$

其中 N 和 M 分別是頻域(Frequency domain)和時域(Time domain)中 FFT 的長度。

一張 RD map 是由 $N \times M$ 個 RD 箱(RD bin)所組成，另外需要注意的是執行 2D FFT 的操作後會產生 $10 \log_{10}(NM)$ dB 的處理增益(Processing gain)[7]。最後，為了得到目標相對於雷達之距離與速度，再將 CFAR 檢測方案用於識別 RD map 上的峰(Peak)。




圖 四、產生 CCM 流程圖

第三章 恆虛警率

3.1 恆虛警率概念

實際環境中的雜訊和雜波功率是隨時間變化的非平穩隨機過程(Non-stationary random process)，在實際數據中應用固定的閾值將導致大量的錯誤警報，而且無法達到期望的虛警率[1]。恆虛警率(Constant False Alarm Rate，簡稱 CFAR)[1]、[2]檢測器旨在將背景雜訊或雜波的虛警率保持在固定水平。CFAR 檢測器從周圍的樣本中估計背景雜訊之 Noise level，以設置檢測閾值，該閾值隨著雜訊或雜波的 Noise level 自適應地變化。本章將介紹以下五種類型的 CFAR 檢測器：

- (i) 單元平均恆虛警率(Cell Averaging Constant False Alarm Rate，簡稱 CA-CFAR)
- (ii) 最大單元平均恆虛警率(Greatest Of Cell Averaging Constant False Alarm Rate，簡稱 GO-CFAR)
- (iii) 最小單元平均恆虛警率(Smallest Of Cell Averaging Constant False Alarm Rate，簡稱 SO-CFAR)
- (iv) 有序統計平均恆虛警率(Order Statistic Constant False Alarm Rate，簡稱 OS-CFAR)
- (v) 深度學習平均恆虛警率(Deep Learning Constant False Alarm Rate，簡稱 DL-CFAR)

3.2 恆虛警率檢測器

本小節將介紹 CFAR 檢測器的架構，如圖 所示。CFAR 檢測器包含四個主要元素：(i) 被測單元(CUT)，(ii) 保護單元(Guard cell)，(iii) 參考單元和 (iv) CFAR 常數 B 。這四個元素協助檢測器設置一個閾值，該閾值可隨著背景噪聲或雜波結構自適應地變化。

被測單元位於 CFAR 檢測器的中間，是將要設置閾值的位置，若目標位於 CUT 中，則他應超過閾值並將其判別為目標。保護單元通常位於 CUT 的兩側，如圖五所示，保護單元中的樣本並不會被使用，使用保護單元的原因是可以消除目標所產生出的旁瓣效應，如此一來可以更準確地估計 Noise level。參考單元是 CFAR 檢測器中較外圍的部分，利用這些單元來估計 Noise level，參考單元中的樣本越多，Noise level 的估計就越準確。CFAR 常數的選擇是基於期望得到之虛警率來決定，乘上利用參考單元估計出來的 Noise level 得到適當的閾值。

圖五為二維 CFAR 檢測器之結構，本研究是將 CFAR 檢測器應用於 RD map 上，因此第五章之模擬結果皆是使用二維 CFAR 檢測器。圖六表示一維 CFAR 檢測器之結構，為利於介紹，後續之 CAFR 檢測器將以一維結構表示。


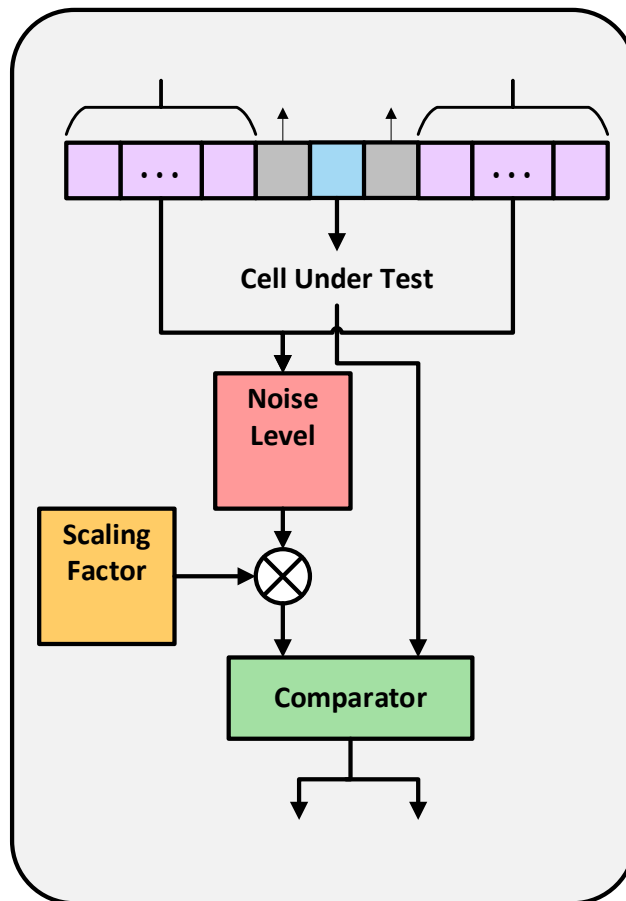


圖 五、CFAR 檢測器之二維結構



圖六、CFAR 檢測器之一維結構

CFAR 檢測器在數據之間移動，並使用參考單元來估計雜訊電平，最後乘以 CFAR 常數得到閾值，將該值與 CUT 進行比較，以確定是否存在目標，CUT 每移動一個單元，則重複上述動作。以下小節將介紹四種傳統的 CFAR 檢測器與一種基於深度學習之 CFAR 檢測器，這五種檢測器將在第五章的模擬結果中與本論文所提出之 YOLO-CFAR 進行效能比較。

3.2.1 單元平均恆虛警率檢測器

單元平均恆虛警率(Cell Averaging Constant False Alarm Rate，簡稱 CA-CFAR)[1]的基本概念是通過對參考單元中的樣本進行平均來估計 Noise level，並且將參考單元的平均值乘以 CFAR 常數，以設置一個可維持所需的虛警率之閾值。CA-CFAR 之結構如圖七所示，其估計 Noise level 的方式可以表示為下式：

$$E_{CA} = \frac{1}{N} \sum_{i=1}^N X_i, \quad (3)$$

其中 E_{CA} 為由 N 個參考單元估計出來的 Noise level， X_i 代表第 i 個參考單元。

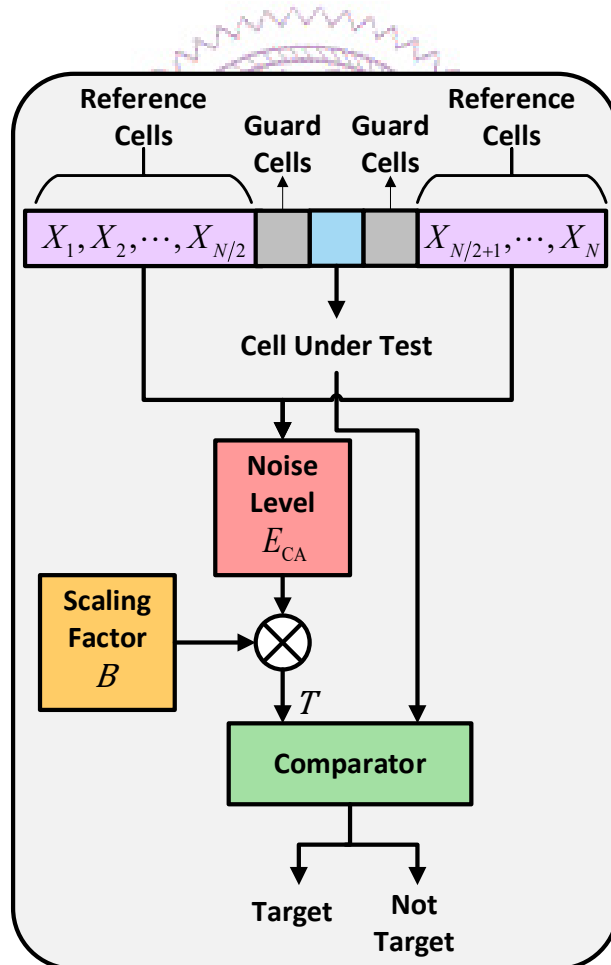
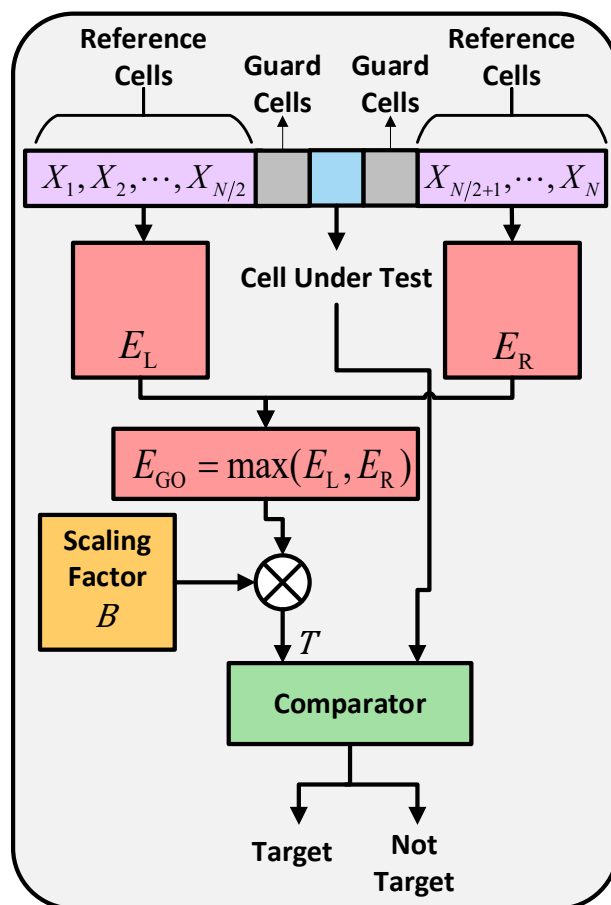


圖 七、CA-CFAR 之一維結構

3.2.2 最大單元平均恆虛警率檢測器

最大單元平均恆虛警率(Greatest Of Cell Averaging Constant False Alarm Rate，簡稱 GO-CFAR)[3]的主要作用在於降低虛警率，GO-CFAR 之結構如圖八所示。



圖八、GO-CFAR 之一維結構

CA-CFAR 和 GO-CFAR 的區別在於，GO-CFAR 分別計算參考單元兩側的平均雜訊功率，然後選擇其中較大的一個，其估計 Noise level 的方式可以表示為下列三式：

$$E_L = \frac{2}{N} \sum_{i=1}^{N/2} X_i , \quad (4)$$

$$E_R = \frac{2}{N} \sum_{i=N/2+1}^N X_i , \quad (5)$$

$$E_{GO} = \max(E_L, E_R) , \quad (6)$$

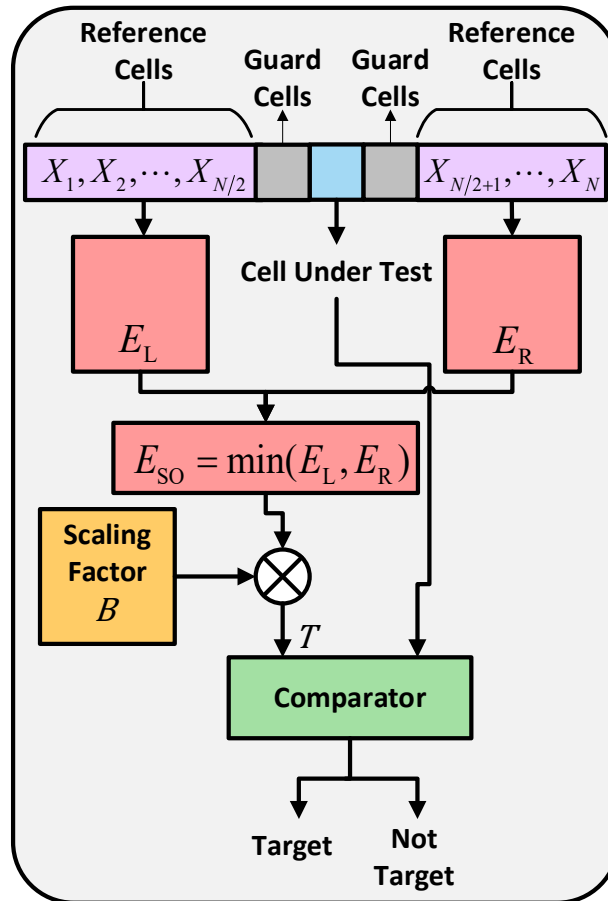
其中 E_L 和 E_R 分別為由左右兩邊之參考單元估計出來的 Noise level， X_i 代表第 i 個參考單元， E_{GO} 為 GO-CFAR 之 Noise level。



3.2.3 最小單元平均恆虛警率檢測器

最小單元平均恆虛警率(Smallest Of Cell Averaging Constant False Alarm Rate，簡稱 SO-CFAR)[4]的主要作用在於解決相鄰目標之間彼此遮蔽的問題，同時也可提升檢測率，SO-CFAR 之結構如圖九所示，分別計算參考單元兩側的平均雜訊功率，並選擇較小的一個，除了在 SO-CFAR 中選擇較小的一側外，SO-CFAR 的結構與 GO-CFAR 幾乎相同，圖中之 E_L 及 E_R 同式(4)及式(5)， E_{SO} 代表 SO-CFAR 的 Noise level，其數學式為：

$$E_{SO} = \min(E_L, E_R)。$$
 (7)



圖九、SO-CFAR 之一維結構

3.2.4 有序統計恆虛警率檢測器

有序統計恆虛警率(Order Statistic Constant False Alarm Rate，簡稱 OS-CFAR)[5]、[6]的主要在克服密集目標之間互相遮蔽的問題，OS-CFAR 與上述三種 CFAR 估計 Noise level 的方式較為不同，其結構如圖十所示，OS-CFAR 檢測器根據功率對參考單元中的樣本進行由小到大的排序，然後選擇第 k 個樣本，以估計環境中的 Noise level，在實際應用中 k 通常設置為 $\frac{3}{4}N$ [5]，其中 N 為參考單元的數量， E_{OS} 代表 OS-CFAR 之 Noise level。

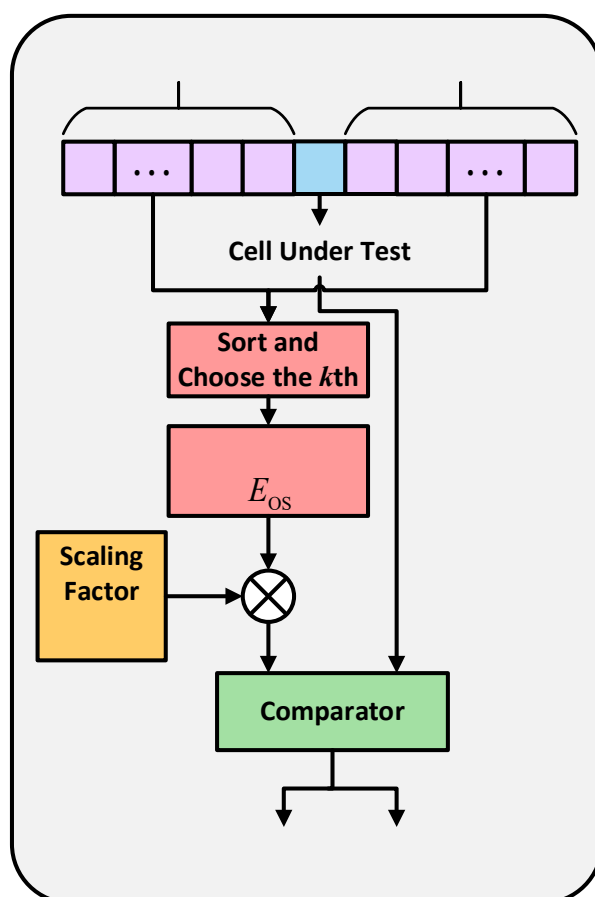


圖 十、OS-CFAR 之一維結構

3.2.5 深度學習恆虛警率檢測器

深度學習平均恆虛警率(Deep Learning Constant False Alarm Rate，簡稱 DL-CFAR)[7]之主要概念為利用深度學習來識別目標並且移除原始 RD map 上的目標，來獲得更準確的 Noise level 之估計。

DL-CFAR 之詳細流程如圖十一所示，在圖十一的(a)中將原始 RD map 經過截斷(Truncate)運算，在文獻[7]中，其截斷閾值設置為 10，接下來將經截斷運算後之 RD map 作為神經網路的輸入，如圖十一的(b)中所示，可以將已截斷的 RD map 視為已截斷的目標 RD map 與純雜訊 RD map 之組合。DL-CFAR 的神經網路可以移除已截斷的 RD map 中之目標，從而得到近似純雜訊之 RD map，並準確估計 RD map 中之 Noise level。

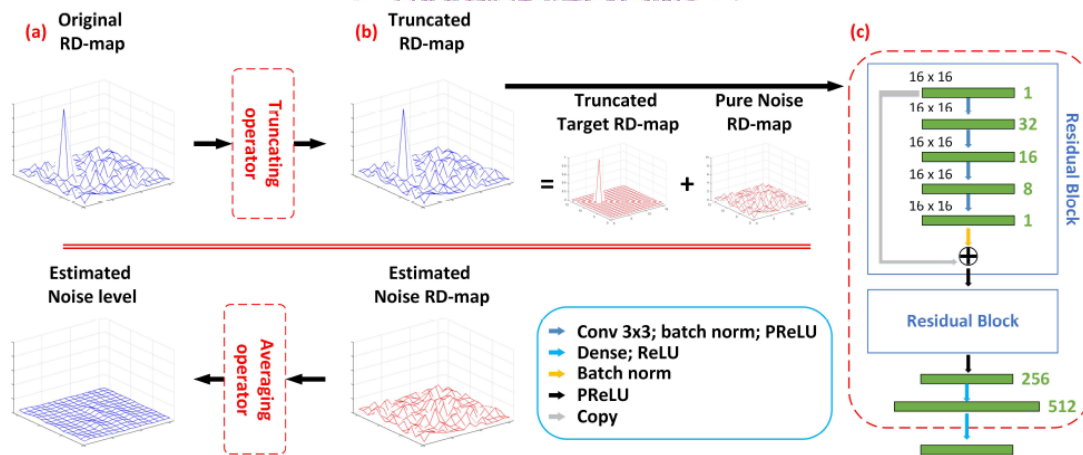


圖 十一、DL-CFAR 之流程圖[7]

第四章 本論文所提出 YOLO-CFAR 演算法

4.1 總覽 YOLO-CFAR

本論文所提出之 YOLO-CFAR 目標偵測演算法其主要概念如圖十二所示，將 RD map 視為一張圖片使用深度學習中物件偵測之模型(即 YOLO)來框出目標物並且給予其信心程度(C Confidence)。如此一來，我們可以避開因為 Noise level 估計不準確而造成 CFAR 檢測器效能下降的問題。

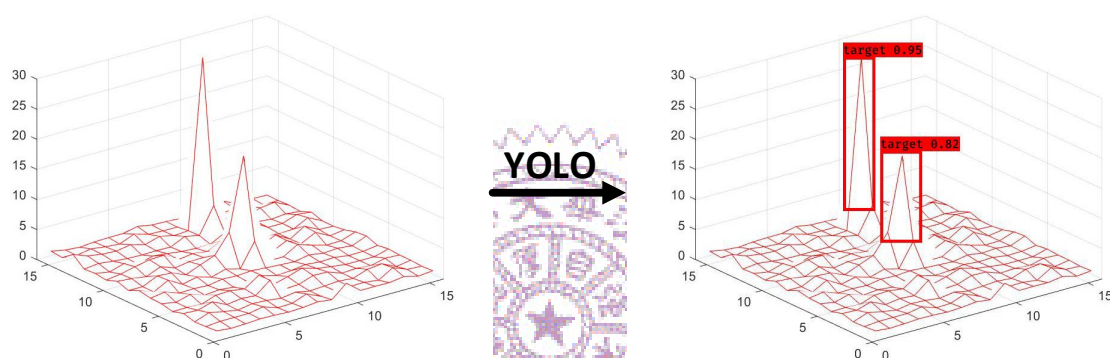


圖 十二、YOLO-CFAR 示意圖

YOLO-CFAR 算法流程如圖十三所示，其中(a)原始的 RD map，經過動態範圍壓縮(Dynamic Range Compression，簡稱 DRC)[13]後，得到(b)壓縮過的 RD map，再將其輸入到(c)YOLO 模型中，在輸出的部分會得到兩個資訊，分別是邊界框(Bounding Box)及其信心程度，將 Bounding Box 所框出的單元輸入到(d)深度神經網路(Deep Neural Network，簡稱 DNN)中，其用意為預測邊界框中每個單元存在目標的機率，最後將 DNN 預測的機率乘上邊界框的信心程度，即可得到最後的結果，因此 YOLO-CFAR 最後的輸出為一機率值。在接下來的幾個小節中，將介紹 YOLO-CFAR 算法中所使用到的動態範圍壓縮、YOLO 網路架構和深度神經網路。

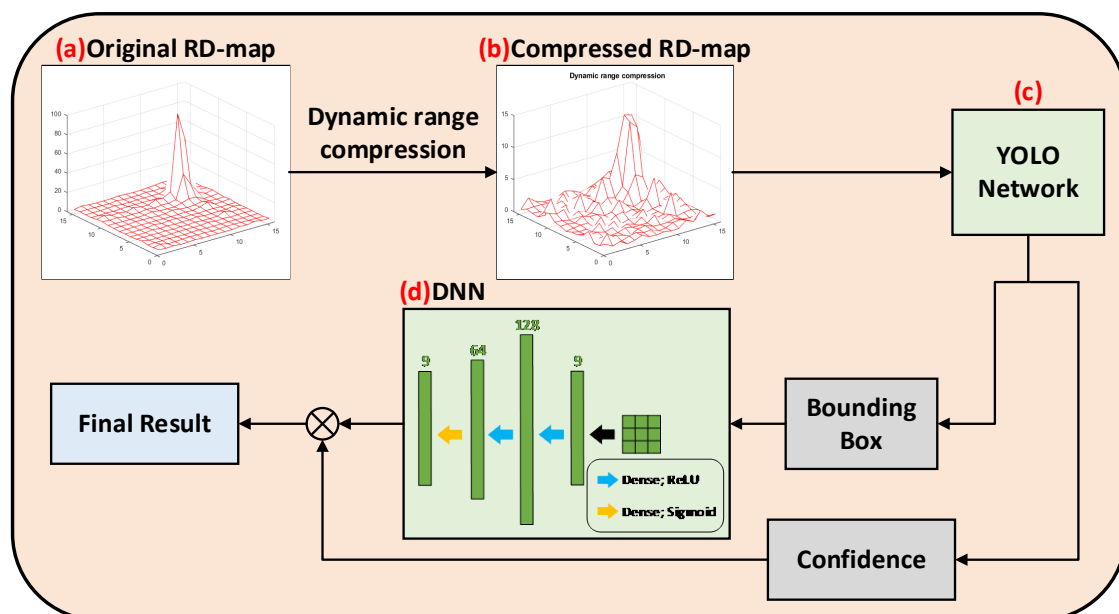


圖 十三、YOLO-CFAR 流程示意圖



4.2 動態範圍壓縮

因本研究之模型必須要可以處理不同 SNR 下的 RD map，在傳統上通常是在輸入神經網路前進行歸一化(Normalize)，但是使用歸一化可能會造成在高 SNR 時的雜訊功率趨近於零，進而導致模型抗雜訊能力下降，因此在 YOLO-CFAR 中採用動態範圍壓縮(Dynamic Range Compression，簡稱 DRC)[13]來做資料前處理。

DRC 常應用於音效的處理上，根據設置的比率降低音樂中響度的峰值，使音量不會過高或過尖，因為是動態的壓縮，也不會使得原本音量較低的部分經壓縮後反而聽不見，例如在電影裡，即使在吵雜的環境中，仍然可以聽見演員的對話。

同理，經過 DRC 的 RD map，降低了目標的峰值，但其雜訊不會經壓縮後就趨近零，更利於提升模型的抗雜訊能力。除此之外，使用 DRC 來做資料的前處理，更可讓目標的旁辦特徵更加明顯，有利於模型的學習，其輸入輸出關係圖如圖十四所示，以下用數學式來表達(a)、(b)、(c)三個部分的輸出輸入關係：

$$(a) \text{RDM}(n, m) < T - \frac{w}{2},$$

$$\widehat{\text{RDM}}(n, m) = \text{RDM}(n, m), \quad (8)$$

$$(b) T - \frac{w}{2} \leq \text{RDM}(n, m) \leq T + \frac{w}{2},$$

$$\widehat{\text{RDM}}(n, m) = \text{RDM}(n, m) + \frac{\left(\frac{1}{R}-1\right)\left(\text{RDM}(n, m)-T+\frac{w}{2}\right)^2}{2w}, \quad (9)$$

$$(c) \text{RDM}(n, m) < T + \frac{w}{2},$$

$$\widehat{\text{RDM}}(n, m) = T + \frac{\text{RDM}(n, m) - T}{R}, \quad (10)$$

其中 T 為閾值，超過此閾值後壓縮比率會逐漸提高， W 為膝蓋寬度(Knee width)，因輸入輸出圖形狀似膝蓋而得名， R 為壓縮比率，在本研究中依據經驗法則，將 T 、 W 、 R 分別設為 12、16、88。




圖 十四、動態範圍壓縮

4.3 YOLO 介紹

在本節的第一小節中會先對深度學習之物件偵測做簡介，第二小節介紹 YOLO 的模型架構以及運作原理，本論文所使用之 YOLOv3[8]模型為原始 YOLOv3 模型精簡化過後的架構，簡化後的網路架構將在第三小節中介紹。

4.3.1 深度學習之物件偵測介紹

在深度學習中用來執行物件偵測(Object detection)的模型分為兩大類，分別是兩階段式(Two-stage)與一階段式(One-stage)[14]，其流程如圖十五所示。

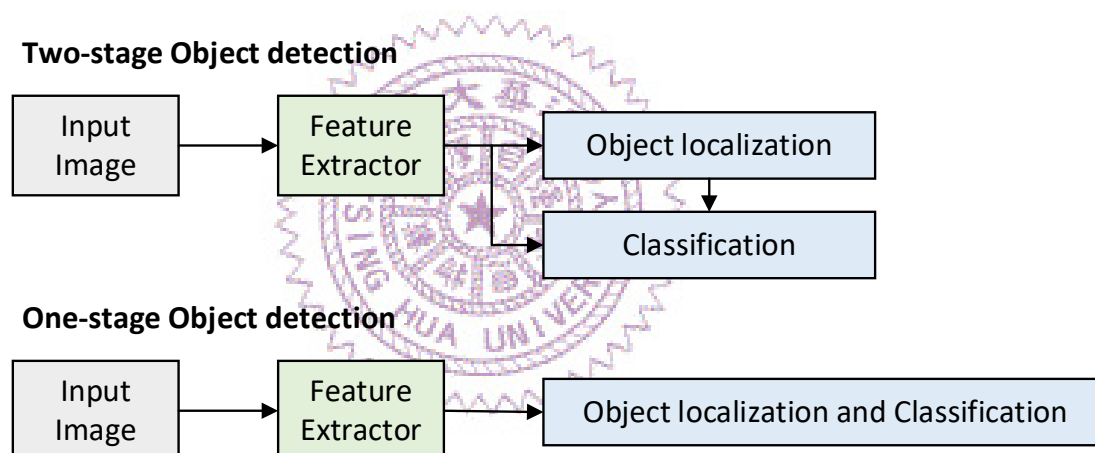


圖 十五、一階段式與兩階段式模型之流程圖

兩階段式的模型是擷取特徵後先做物件偵測，偵測結果再交由分類器去辨識物件類別，其中偵測器與分類器會共享特徵。一階段式的模型擷取特徵後會同時做物件偵測與分類。以優缺點來說，因兩階段式模型之偵測與分類是各別訓練及串聯應用，所以其效率較低，但準確度較高，而一階段式模型是偵測與分類是同時訓練，所以效率較高，只是準確度相對較低。

由於一階段式模型檢測速度快且準確度也在可接受的範圍內，因此是目前物件偵測的主流方案，本研究所使用之 YOLO 即是屬於一階段式模型。

4.3.2 YOLO 技術介紹

本研究所採用的模型 YOLO(You Only Look Once)，該模型是一種基於深度學習的卷積神經網路(Convolutional Neural Network，簡稱 CNN)，主要用來做物件偵測，其偵測示意圖如圖十六所示，最主要特色是 YOLO 僅需經過單個 CNN 即可判別物件的位置與類別，因此偵測的速度特別快，其最大的優點就是可以達到實時檢測。YOLOv1[15]在於 2016 被提出，在 2017 年，其作者又提出了 YOLOv2[16]，進一步提升了檢測的精度與速度，於 2018 年作者再度對 YOLO 做了改進，提出 YOLOv3[8]，改善了對小物體的偵測能力，本研究所採用的模型為 YOLOv3，因此本小節將針對 YOLOv3 的技術內容做介紹。




圖 十六、YOLO 偵測示意圖[12]

YOLO 的偵測方式是將輸入的圖片分割成 $S \times S$ 個網格(Grid cell)，欲偵測之物件的中心點所在之網格則負責偵測該物件，在 YOLOv3 中每個網格會有 3 個邊界框(Bounding box)去偵測物件[8]，在神經網路最後的輸出中，每個邊界框會輸出三類參數，分別是邊界框資訊、信心程度(Confidence)以及類別機率(Class probability)，以下對三類參數做介紹。

邊界框的資訊有四個數值，分別是邊界框的長、寬和中心點座標，其中網路預測得長和寬為相對於錨點框(Anchor box，或稱為 Bounding box prior)[17]的尺度縮放 t_w 、 t_h ，而中心點座標則是相對於該網格左上角座標之偏移量 t_x 、 t_y ，如圖十七所示，最後要將模型所預測的數值轉換為實際邊界框的資訊需透過下列公式：

$$b_x = \sigma(t_x) + c_x, \quad (11)$$

$$b_y = \sigma(t_y) + c_y, \quad (12)$$

$$b_w = p_w e^{t_w}, \quad (13)$$

$$b_h = p_h e^{t_h}, \quad (14)$$

其中 b_w 、 b_h 為邊界框實際的長寬， b_x 、 b_y 為邊界框實際的中心點座標， c_x 、 c_y 為網格之左上角座標， p_w 、 p_h 為錨點框的長寬， $\sigma(\cdot)$ 為 Sigmoid 函數。關於錨點框，作者在 YOLOv2 及 YOLOv3 中皆使用了預先定義的錨點框，其定義的方法是從訓練集中的資料統計出最常出現的邊界框之形狀和尺寸，透過預先定義的錨點框，有助於降低神經網路盲找的可能性，使得模型可以更快收斂。

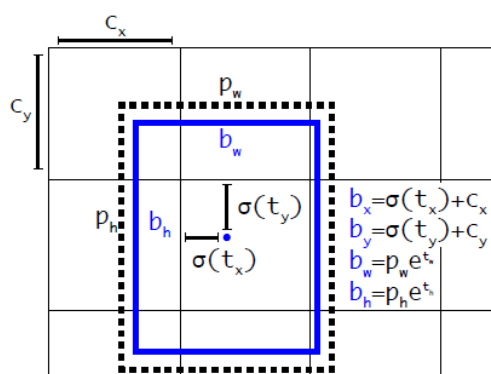


圖 十七、邊界框的預測值與實際值之示意圖[8]

信心程度代表此邊界框中有物件的機率，並且乘上若有物件時預測的邊界框與物件真實的邊界框之交並比(Intersection Over Union，簡稱 IOU)的值，需注意的是在測試時物件真實的邊界框並不存在，因此 Confidence 只是用來表達模型框出物件的自信程度，寫成數學式可表示為：

$$C_{i,j} = \text{Pr}(\text{Object}) \times \text{IOU}_{\text{pred}}^{\text{truth}}, \quad (15)$$

其中 $C_{i,j}$ 為第 i 個網格中的第 j 個邊界框之信心程度。第三類參數則是類別機率，類別機率為條件機率 $\text{Pr}(\text{Class}_z|\text{Object})$ ，在邊界框有物件的前提下物件屬於類別 z 的機率。從上述介紹可得，最後神經網路的輸出維度為 $S \times S \times [3 \times (4 + 1 + n_{\text{class}})]$ ，其中 n_{class} 為類別數量。在訓練的階段，YOLOv3 在邊界框資訊(即 t_x 、 t_y 、 t_w 、 t_h)預測的部分所使用的損失函數(Loss function)為平方和誤差(Sum of square error)，在信心程度及類別機率預測的部分使用的損失函數為二元交叉熵(Binary cross-entropy)。

圖十八為 YOLOv3 的網路架構，YOLOv3 的特徵提取器為 Darknet-53，因有 53 層卷積層而得名，隨著網路層數的加深，在 Darknet-53 中採用了殘差神經網路(Residual Network，簡稱 ResNet)[18]來解決梯度問題，在特徵提取器後面，借鑒了特徵金字塔網路(Feature Pyramid Networks，簡稱 FPN)[19]的想法，在模型中加入了多尺度預測，使用 FPN 的架構可以讓低層較佳的目標位置和高層較佳的語義特徵融合，並且在三個不同尺寸的特徵層(Feature map)獨立進行預測，使得小物體檢測改善效果十分明顯。此處以 COCO 數據集為例，有 80 個類別，因此 YOLOv3 最後的輸出維度為 $S \times S \times [3 \times (4 + 1 + 80)]$ 。

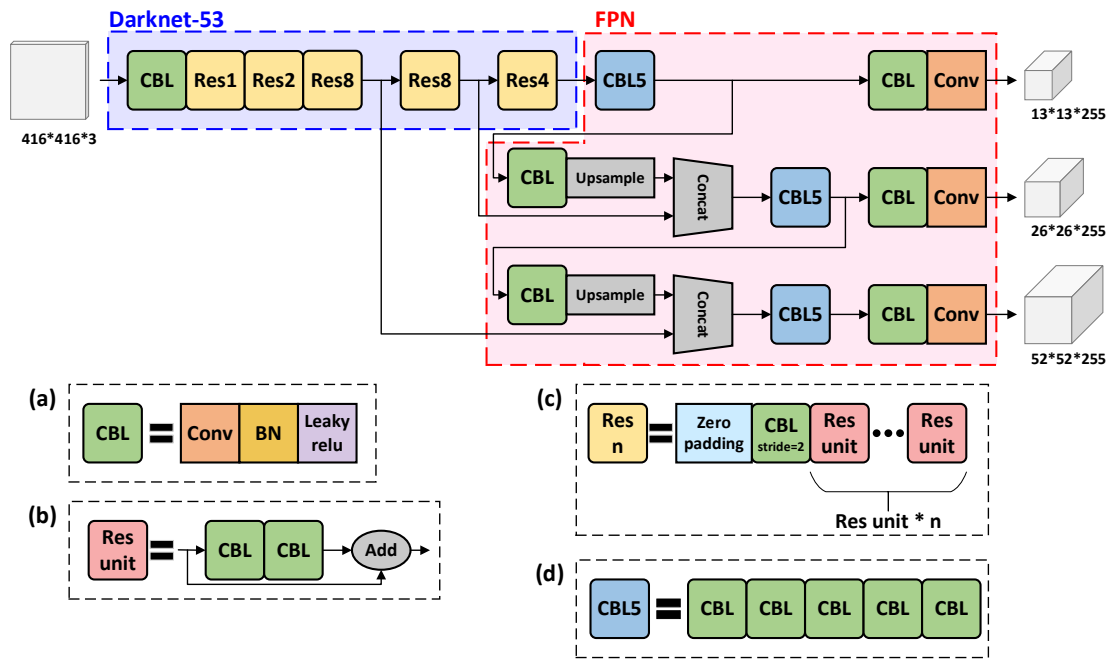


圖 十八、YOLOv3 之網路架構

YOLO 最大的優點即為速度快，在 YOLOv3 中，以 416×416 的輸入圖片為例，其運算速度可達每秒 34 張影格，即 34FPS(Frame per second)，此速度即可達到即時檢測(大於 30FPS)。

4.3.3 簡化 YOLO 模型

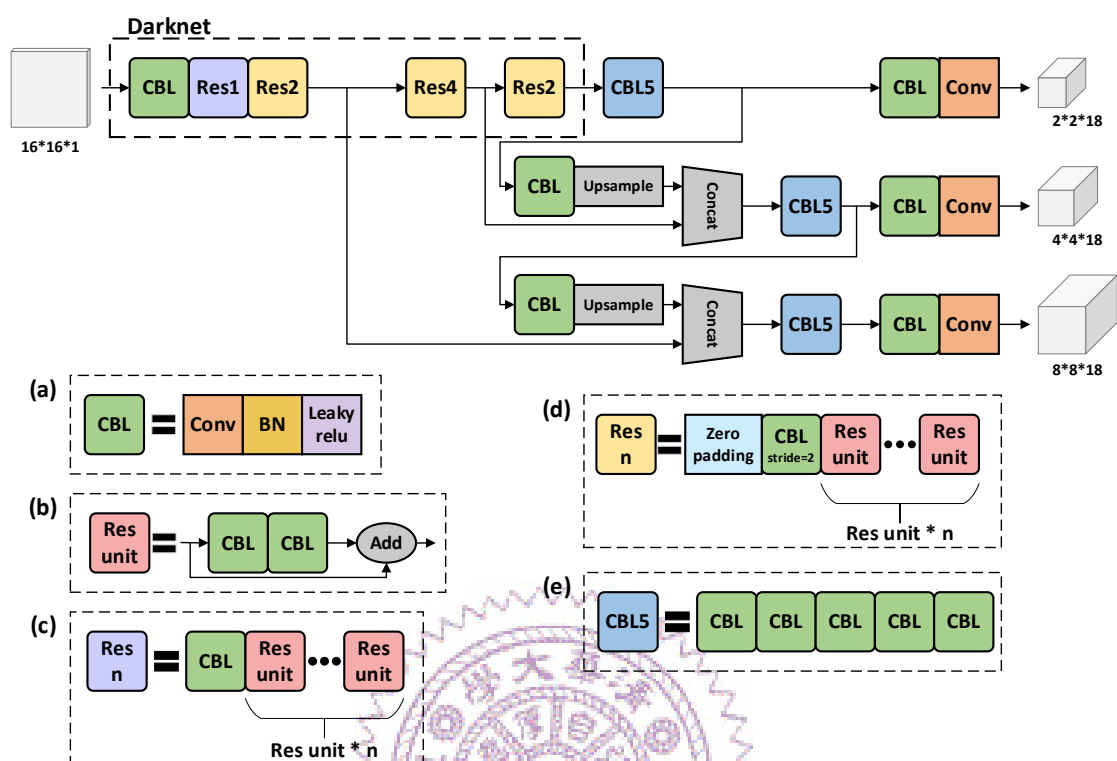


圖 十九、簡化後之 YOLOv3 網路架構

YOLO 在以往的偵測任務中，需偵測的種類往往達到數十種，並且相較於本研究其偵測的物品通常特徵較為多樣且複雜，而在本研究中只需要 YOLO 來偵測目標，不僅種類數量大幅減少，特徵也較為簡單，因此在本研究中我們對 YOLOv3 的網路架構做了簡化，主要簡化的部分為特徵提取器 Darknet 的部分，如圖十九，使參數量降為原本的三分之一，如此一來，除了解決因模型過於複雜而造成的過度學習(Overfitting)問題外，也降低了整體的計算複雜度，更優化了 YOLO 所輸出的效能。

4.4 深度神經網路

為了進一步提升 YOLO-CFAR 之效能，我們設計了一個簡單的深度神經網路(Deep Neural Network，簡稱 DNN)接在 YOLO 模型的後面，去預測 YOLO 輸出的邊界框中每一個單元存在目標的機率，並且將此問題視為一個多標籤分類(Multi-label classification)的問題，此神經網路是由密集層(Dense layer)所組成的，其網路架構如圖二十所示，前兩層所使用的激活函數(Activation function)為常見的 ReLU(Rectified Linear Unit)，其數學式定義為：

$$\text{ReLU}(x) = \max(0, x), \quad (16)$$

最後一層所使用的激活函數為 Sigmoid，此函數會將輸出值映射為機率，且其結果相互獨立，其數學式定義為：

$$\text{Sigmoid}(x) = \frac{1}{1+e^{-x}}, \quad (17)$$

，在訓練階段使用的損失函數為在多標籤分類問題常用的二元交叉熵。

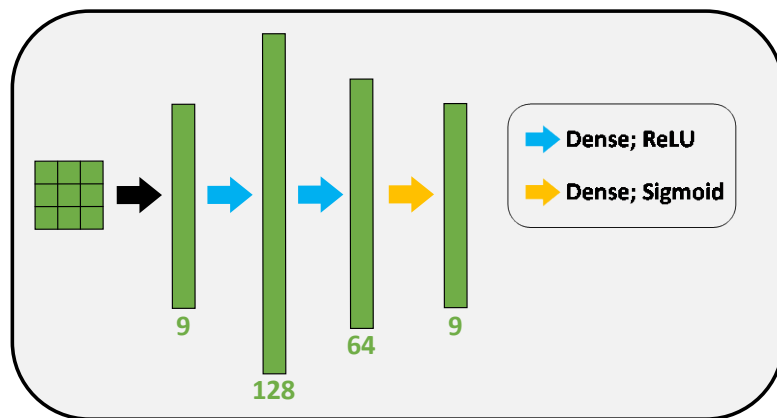


圖 二十、深度神經網路之架構圖

第五章 模擬結果與分析

5.1 模擬環境與比較對象

在本論文的模擬中，我們將研究 YOLO-CFAR 檢測器在均質、多目標和雜波環境中的性能，並且與五個現有的 CFAR 算法進行了比較：DL-CFAR、CA-CFAR、GO-CFAR、SO-CFAR 和 OS-CFAR。根據[7]中的設定，以下模擬中所使用的 RD map 大小均為 16×16 。

5.2 訓練資料產生與設定

在下一小節的模擬中，訊號雜訊比(Signal-to-noise ratio，簡稱 SNR)之定義為在 RD bin 觀察到的訊號雜訊比。對於 YOLO 和 DNN，我們的訓練集(Training set)、驗證集(Validation set)和測試集(Testing set)的數量皆分別為 200000、60000 和 200000 筆資料，其中訓練集資料中皆有包含單目標、多目標及雜波的資料。關於 DRC 之參數設置，在本論文中之設置為 $T = 12$ 、 $W = 16$ 、 $R = 88$ 。本文提供的所有模擬結果均代表測試集的平均結果，不包括訓練集和驗證集。

5.3 模擬結果

在本論文的模擬中，我們考慮了三種不同情境、YOLO-CFAR 資料前處理方法比較、是否加入深度神經網路之比較：

(情景一) 單目標環境。

(情景二) 多目標環境。

(情景三) 雜波環境。

(比較一) 加入深度神經網路前後之比較。

(比較二) 動態範圍壓縮與截斷運算之比較。

5.3.1 單目標環境

在此小節中我們將討論不同 CFAR 檢測器在單目標環境、不同 SNR 下， P_d 與 P_{fa} 的關係，根據[20]，當 SNR 大於 30 dB 時，目標可以成功被檢測到，因此以下模擬著重在 SNR = 20 dB、25 dB、30 dB。

圖二十一顯示了不同 CFAR 檢測器在低 SNR 時 P_d 與 P_{fa} 之間的關係。從圖十中可看出，雖 CA-CFAR 與其變形在均質環境中均有良好的效能，但兩種基於深度學習之 CFAR 檢測器 YOLO-CFAR、DL-CFAR 的效能皆更勝於傳統 CFAR，而 YOLO-CFAR 明顯是所有 CFAR 檢測器中效能最好之檢測器。

圖二十二和圖二十三分別顯示不同 CFAR 檢測器在中 SNR 和高 SNR 時 P_d 與 P_{fa} 之間的關係。從模擬結果中可以看到，兩種基於深度學習之 CFAR 檢測器 YOLO-CFAR、DL-CFAR 的效能皆勝於傳統 CFAR，但在中高 SNR 時，YOLO-CFAR 效能無勝出，而是與 DL-CFAR 效能相近。

儘管傳統的 CFAR 檢測器採用保護單元來防止由旁瓣引起的高估噪聲水平現象，但由於固定大小的保護單元無法處理各種類型的旁瓣，因此其效能會下降，而通過採用深度學習技術，使得 CFAR 檢測器可以透過目標特徵來識別或移除不同場景下的目標，進而改善 CFAR 檢測器之效能，因此基於深度學習之 CFAR 效能會優於傳統 CFAR。而在兩種基於深度學習之 CFAR 檢測器中，相較於 DL-CFAR 較簡單的模型設計，YOLO 的模型較深且複雜，它擁有出色的特徵提取器：Darknet，且 YOLO 模型中的多尺度預測提升了其對小物體的偵測能力，這些模型上的設計讓其對物體的細節資訊掌握得較精確，所以在低 SNR 的環境中即使目標特徵較不明顯還是可以將其辨認出來，因此 YOLO-CFAR 的抗雜訊能力也較 DL-CFAR 佳。

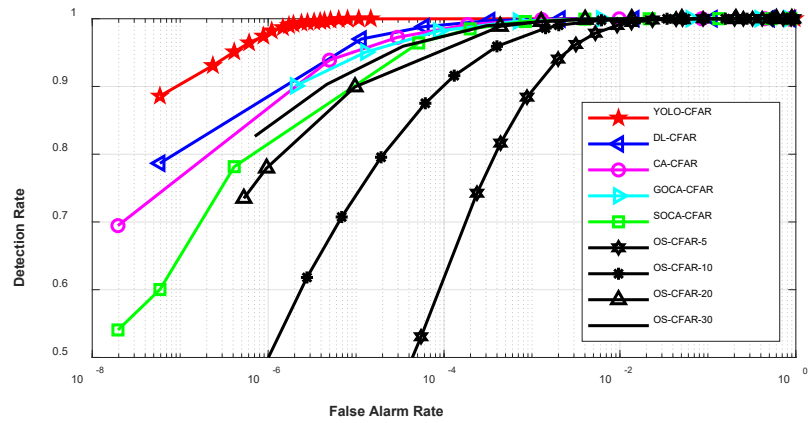


圖 二十一、單目標環境且 $\text{SNR} = 20 \text{ dB}$ (低 SNR)

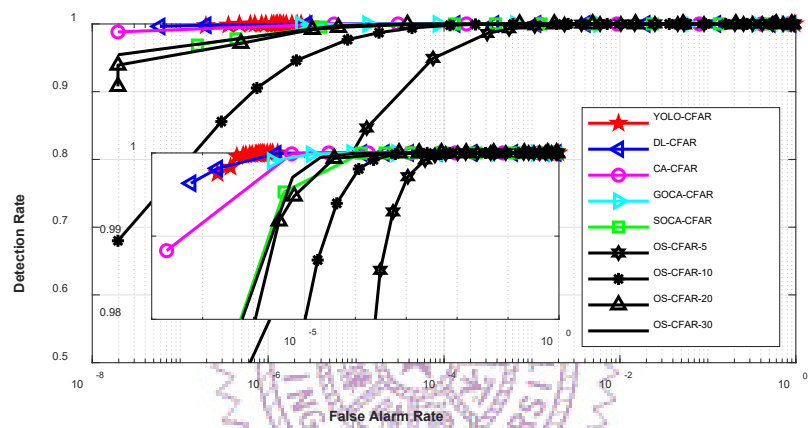


圖 二十二、單目標環境且 $\text{SNR} = 25 \text{ dB}$ (中 SNR)




圖 二十三、單目標環境且 $\text{SNR} = 30 \text{ dB}$ (高 SNR)

5.3.2 多目標環境

在此小節我們將討論不同 CFAR 檢測器在多目標環境中之 P_d 與 P_{fa} 的關係，並對模擬結果進行分析。

圖二十四顯示了兩個目標且 SNR = 20 dB 的情況，不同 CFAR 檢測器的 P_d 與 P_{fa} 。從圖二十四可看出 YOLO-CFAR 的效能明顯優於其他算法，當 $P_{fa} = 10^{-6}$ 時 YOLO-CFAR 的 P_d 比起他 CFAR 檢測器高出至少 7%。圖二十五和圖二十六顯示了在 SNR = 20 dB 時場景中存在三個目標和四個目標的模擬結果。YOLO-CFAR 之效能仍然勝過其他 CFAR 之效能，當 $P_{fa} = 10^{-6}$ 時 YOLO-CFAR 的 P_d 比起他 CFAR 檢測器高出至少 7%。

由於遮蔽效應之影響，除了 OS-CFAR 以外的傳統 CFAR 在多目標環境中效能皆明顯下降，因為其在 Noise level 的估計中包含目標，導致 Noise level 被高估使效能下降。而兩種基於深度學習之 CFAR 檢測器中，YOLO-CFAR 效能又更勝於 DL-CFAR 效能，雖然 DL-CFAR 透過移除目標來解決遮蔽效應的問題，但 DL-CFAR 跟傳統 CFAR 一樣是先估計 Noise level 再經比較得到檢測結果，因此，還是有可能會產生因 Noise level 估計不準確所導致的錯誤延遲使其效能下降。




圖 二十四、兩個目標且 $\text{SNR} = 20 \text{ dB}$

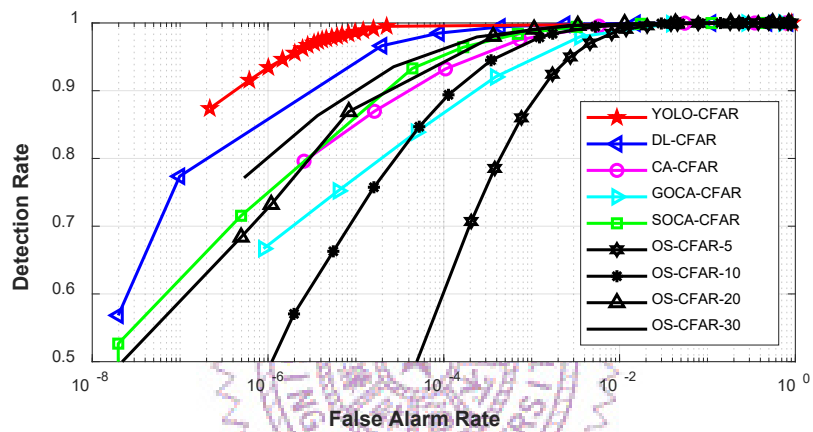


圖 二十五、三個目標且 $\text{SNR} = 20 \text{ dB}$

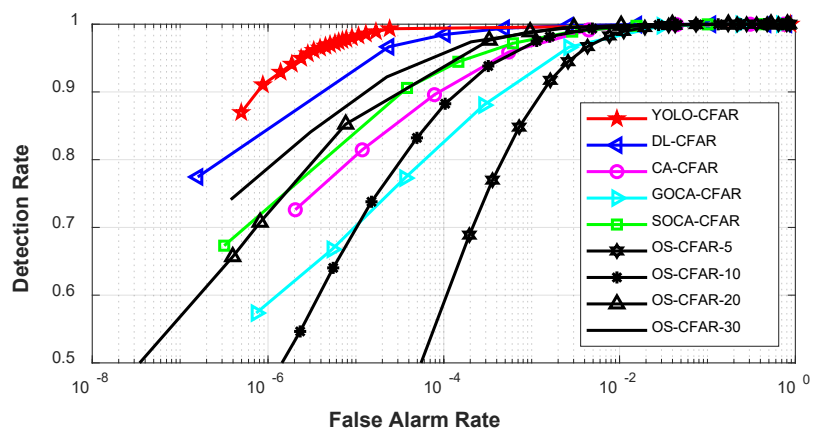


圖 二十六、四個目標且 $\text{SNR} = 20 \text{ dB}$

5.3.3 雜波環境

在此小節中我們將分析不同 CFAR 檢測器在雜波環境中的效能表現，本模擬將依據不同雜波雜訊比(Clutter-to-noise ratio, 簡稱 CNR)、SNR 及目標數量來進行討論。

我們將 CFAR 檢測器分成兩種來討論，分別是 one-step 和 two-step，因 YOLO-CFAR 是直接對目標做偵測因此歸類到 one-step，其餘的 CFAR 檢測器因為需先對 Noise level 做估計再將 CUT 與閾值做比較，所以歸類到 two-step。Two-step 之 CFAR 的效能容易因 Noise level 估計不準確導致其效能下降，影響 Noise level 的因素有旁瓣問題、遮蔽效應、雜波邊緣，前兩者已經分別在前兩小節部分討論，而雜波的問題將在下方做討論。

圖二十七到圖二十九的模擬環境是 $\text{SNR} = 20 \text{ dB}$ 、單目標，CNR 分別是 10 dB 、 15 dB 、 20 dB 。可以明顯看出 Two-step 之 CFAR 效能嚴重下降，而 YOLO-CFAR 在 $P_{fa} = 10^{-4}$ 時還能保持 90% 的 P_d 。圖三十至圖三十二顯示模擬環境為 $\text{SNR} = 20 \text{ dB}$ 、 $\text{CNR} = 20 \text{ dB}$ ，目標數量分別為二、三、四的模擬結果。從圖中可看出即使在有雜波且多目標的複雜環境中 YOLO-CFAR 的性能仍明顯優於其他 Two-step 之 CFAR 算法。

由模擬結果可證明 YOLO 提取特徵的能力非常強大，即使在雜波環境中仍能抓到目標的特徵，且少了估計 Noise level 的步驟，YOLO-CFAR 並不會產生因錯估 Noise level 而造成的錯誤延遲。而 DL-CFAR，雖然在單目標及多目標環境下表現良好，但其模型在雜波環境中的效能嚴重下降，在 $\text{CNR} = 20 \text{ dB}$ 的環境中，DL-CFAR 之效能甚至掉得比傳統 CFAR 還低。




圖 二十七、單目標且 $SNR = 20$ dB、 $CNR = 10$ dB

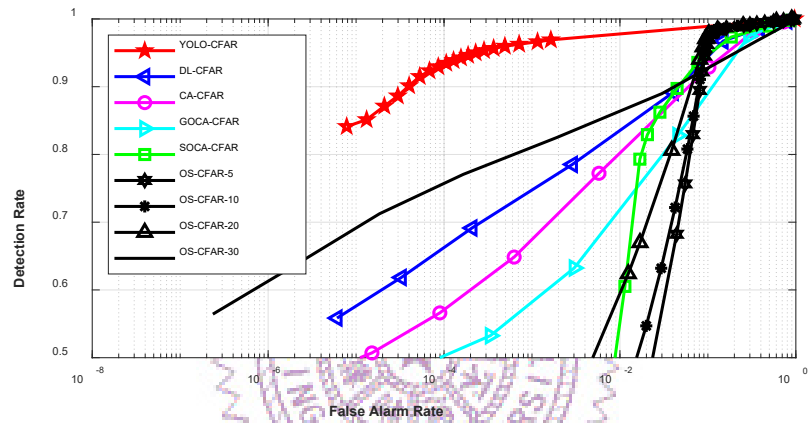


圖 二十八、單目標且 $SNR = 20$ dB、 $CNR = 15$ dB

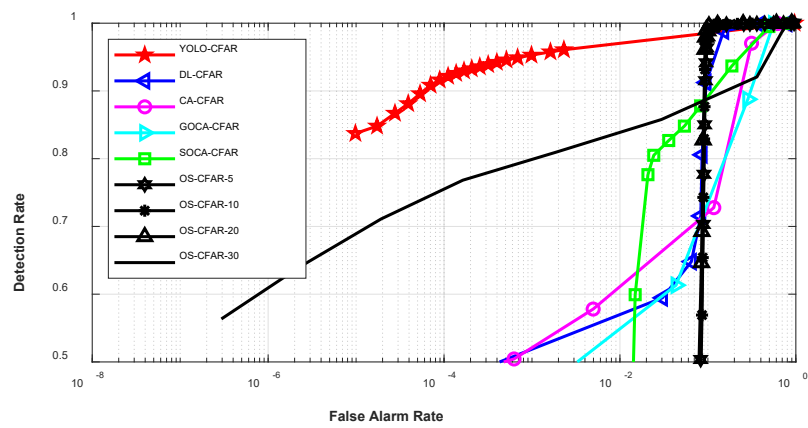


圖 二十九、單目標且 $SNR = 20$ dB、 $CNR = 20$ dB

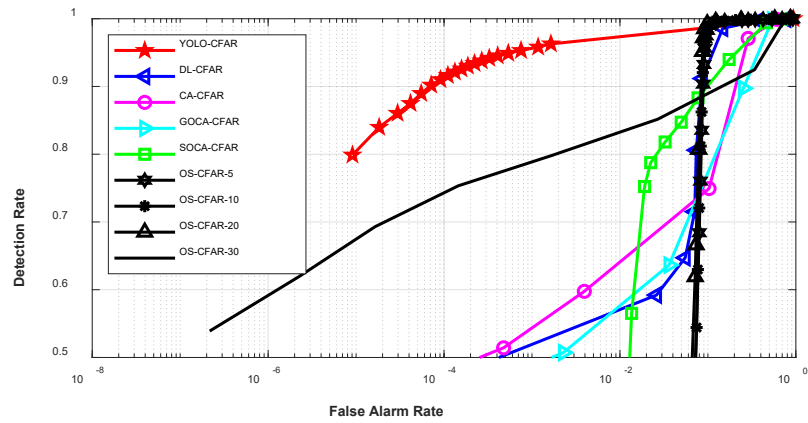


圖 三十、兩個目標且 $\text{SNR} = 20 \text{ dB}$ 、 $\text{CNR} = 20 \text{ dB}$




圖 三十一、三個目標且 $\text{SNR} = 20 \text{ dB}$ 、 $\text{CNR} = 20 \text{ dB}$




圖 三十二、四個目標且 $\text{SNR} = 20 \text{ dB}$ 、 $\text{CNR} = 20 \text{ dB}$

5.3.4 加入深度神經網路與否之比較

在此小節中我們將比較在多目標環境中 YOLO-CFAR 加入深度神經網路前後之效能改善。因為 YOLO 本身沒辦法分辨兩個相鄰的目標（只會輸出一個 Bounding box），所以我們在 YOLO 的輸出加上一個 DNN 來幫助區分相鄰目標，圖三十三到圖三十五為 $\text{SNR} = 20 \text{ dB}$ ，目標數量分別為二、三、四之模擬結果。從圖中可看出，隨著目標數量的增加，加入 DNN 後的改善幅度越明顯。




圖 三十三、兩個目標且 $\text{SNR} = 20 \text{ dB}$




圖 三十四、三個目標且 $\text{SNR} = 20 \text{ dB}$




圖 三十五、四個目標且 $\text{SNR} = 20 \text{ dB}$

5.3.5 使用動態範圍壓縮與使用截斷運算之比較

在此小節中我們將比較在資料前處理的部分使用動態範圍壓縮與使用截斷運算(Truncating operator)之效能。本小節之截斷運算的閾值根據參考文獻[7]將其設置為 10。

圖三十六為 YOLO-CFAR 與 DL-CFAR 分別使用 DRC 與截斷運算之效能比較，從圖中可看出，不論 YOLO-CFAR 還是 DL-CFAR，使用 DRC 來做資料前處理之效能皆比使用截斷運算之效能還佳。與截斷運算不同，DRC 是動態的調整，所以可以使目標之旁瓣更加明顯，讓模型能透過此特徵更好的辨認出目標，因此使用 DRC 之效能較佳。




圖 三十六、動態範圍壓縮與截斷運算之比較

第六章 結論

本研究所提出的 YOLO-CFAR 是結合深度學習之物件偵測技術的雷達目標偵測算法，我們將雷達目標偵測的問題轉換為圖片上的物件偵測問題，跟其他現有 CFAR 算法比較，少了對 Noise level 的估計，使得 YOLO-CFAR 的效能不易受到目標返回的旁瓣問題、目標彼此之間的遮蔽效應和雜波的影響，可改善 CFAR 算法在非均質環境中效能低下的問題。為使模型能夠處理不同 SNR 的 RD map 及讓模型更容易學習到目標的特徵，本研究在神經網路的輸入之前應用 DRC 來做資料前處理，而在神經網路的輸出後亦加上 DNN 進一步的提升 YOLO-CFAR 在多目標環境的效能。

在最後的模擬結果中，不論是均質環境還是非均質環境中 YOLO-CFAR 皆有非常出色的表現，特別是在雜波環境，其他現有 CFAR 效能皆明顯下降，而 YOLO-CFAR 還能在虛警率為 10^{-4} 時保持 90% 的檢測率。然而，相較於其他 CFAR 算法，雖然 YOLO-CFAR 之複雜度較高，但其仍可達到即時檢測，在本研究的模擬中，以 16×16 之 RD map 為例，其運算速度可達每秒 71 張影格，因此 YOLO-CFAR 仍是一個兼具速度及準確度的 CFAR 算法，並且非常適合應用在非均質環境中。

參考文獻

- [1] M. A. Richards, J. A. Scheer, and W. A. Holm, "Constant false alarm rate detectors," in *Principles of modern radar*, Raleigh, NC: SciTech Publishing, 2010, pp. 589–620.
- [2] A. Jalil, H. Yousaf, and M. I. Baig, "Analysis of cfar techniques," in *Proc. 13th Int. Bhurban Conf. Appl. Sci. Technol. (IBCAST)*, Jan. 2016, pp. 654–659.
- [3] V. G. Hansen and J. H. Sawyers, "Detectability loss due to greatest of selection in a cell-averaging cfar," *IEEE Trans. Aerosp. Electron. Syst.*, vol. AES-16, no. 1, pp. 115–118, Jan. 1980.
- [4] G. V. Trunk, "Range resolution of targets using automatic detectors," *IEEE Trans. Aerosp. Electron. Syst.*, vol. AES-14, no. 5, pp. 750–755, Sept. 1978.
- [5] H. Rohling, "Radar cfar thresholding in clutter and multiple target situations," *IEEE Trans. Aerosp. Electron. Syst.*, vol. AES-19, no. 4, pp. 608–621, Jul. 1983.
- [6] J. T. Rickard and G. M. Dillard, "Adaptive detection algorithms for multiple-target situations," *IEEE Trans. Aerosp. Electron. Syst.*, vol. AES-13, no. 4, pp. 338–343, July 1977.
- [7] C. Lin, Y. Lin, Y. Bai, W. Chung, T. Lee, and H. Huttunen, "DI-cfar: a novel cfar target detection method based on deep learning," *2019 IEEE 90th Vehicular Technology Conference (VTC2019-Fall)*, Honolulu, HI, USA, Sept. 2019.
- [8] J. Redmon and A. Farhadi, "Yolov3: an incremental improvement," Apr. 2018, *arXiv:1804.02767*. [Online]. Available: <https://arxiv.org/abs/1804.02767>
- [9] A. G. Stove, "Linear fmcw radar techniques," *IEE Proc. F Radar Signal Process.*, vol. 139, no. 5, pp. 343–350, Oct. 1992.

- [10] J. Fink and F. K. Jondral, "Comparison of ofdm radar and chirp sequence radar", *2015 16th Int. Radar Symp.*, pp. 315-320, 2015.
- [11] A. Wojtkiewicz, J. Misiurewicz, M. Nalecz, K. Jedrzejewski, and K. Kulpa, "Two-dimensional signal processing in fmcw radars," in *Proc. 20th KKTOiUE*, Warszawa, Poland, 1996, pp. 475-480.
- [12] M. Kronauge and H. Rohling, "New chirp sequence radar waveform," *IEEE Trans. Aerosp. Electron. Syst.*, vol. 50, no. 4, pp. 2870-2877, Oct. 2014.
- [13] D. Giannoulis, M. Massberg, and J. D. Reiss, "Parameter automation in a dynamic range compressor," *J. Audio Eng. Soc.*, vol. 61, no. 10, Oct. 2013.
- [14] Z.-Q. Zhao, P. Zheng, S.-T. Xu, and X. Wu, "Object detection with deep learning: a review," *IEEE Trans. Neural Netw. Learn. Syst.*, vol. 30, no. 11, pp. 3212-3232, Nov. 2019.
- [15] J. Redmon, S. Divvala, R. Girshick, and A. Farhadi, "You only look once: unified, real-time object detection," in *Proc. IEEE Conf. Comput. Vis. Pattern Recognit. (CVPR)*, June 2016, pp. 779-788.
- [16] J. Redmon and A. Farhadi, "Yolo9000: better, faster, stronger," in *Proc. IEEE Conf. Comput. Vis. Pattern Recognit. (CVPR)*, Jul. 2017, pp. 6517-6525.
- [17] S. Ren, K. He, R. Girshick, and J. Sun, "Faster r-cnn: towards real-time object detection with region proposal networks," *IEEE Trans. Pattern Anal. Mach. Intell.*, vol. 39, no. 6, pp. 1137-1149, Jun. 2017.
- [18] K. He, X. Zhang, S. Ren, and J. Sun, "Deep residual learning for image recognition," in *Proc. IEEE Conf. Comput. Vis. Pattern Recognit.*, Jun. 2016, pp. 770-778.
- [19] T.-Y. Lin, P. Dollar, R. Girshick, K. He, B. Hariharan, and S. Belongie, "Feature pyramid networks for object detection," in *Proc. CVPR*, 2017, pp. 936-944.

- [20]Y. L. Sit and T. Zwick, "Automotive mimo ofdm radar: subcarrier allocation techniques for multiple-user access and doa estimation," in *11th European Radar Conf.*, Oct. 2014, pp. 153–156.

